MANUAL TÉCNICO E DIDÁTICO

Como funciona o NodeWatch

O que o sistema faz, como cada análise é feita, como o Machine Learning é usado e o que os resultados permitem concluir.

Projeto: NodeWatch — Sistema de Detecção de Fraudes em Transações Financeiras (Grupo 4)

Integrantes: Caio Winkler Marangoni, Guilherme Lombardi, Ryan dos Santos Veloso, Julia Emily Leonardo Barbosa e Guilherme Liborio Camargo

Versão documentada: branch ml/sessoes-analise-datasets, a partir do commit 9095451, com as alterações da revisão de confiabilidade

Modelos: estado_rede-20261102T083053Z e lavagem-20261102T083253Z (nenhum foi retreinado para este manual)

Data: 06/11/2026

Sumário

Parte I — Para entender o sistema 5

1 O que é o NodeWatch 6
- 1.1 O problema 6
- 1.2 Quatro coisas que não se confundem 6
- 1.3 O que existe hoje 6

2 Que dados o sistema recebe 8

3 O que acontece numa análise 9
- 3.1 Como o modelo chega a uma nota 9
- 3.2 Como ler um resultado 9
- 3.3 Quais conclusões os dados permitem 9

4 Tutorial completo com dados inventados 11

Parte II — Referência técnica 13

5 Arquitetura 14
- 5.1 Componentes 14
- 5.2 Caminho dos dados 15
- 5.3 O que roda onde 15
- 5.4 Sentinel AI 16

6 Análises financeiras por grafos 17
- 6.1 Ciclos 17
- 6.2 Componentes fortemente conectados (SCC) 17
- 6.3 Centralidade e pontuação de risco 17
- 6.4 Fan-out e fan-in 18
- 6.5 Exemplo 18

7 Telemetria de rede 19

8 Transações financeiras e lavagem 20
- 8.1 Identidade das contas 20
- 8.2 Janelas temporais 20
- 8.3 Os 49 atributos 20
- 8.4 Cálculos 21
- 8.5 Duas implementações dos mesmos atributos 21
- 8.6 Motivos verificáveis 21
- 8.7 Defeitos conhecidos, abertos 22

9 Machine Learning de ponta a ponta 23
- 9.1 Biblioteca não é algoritmo 23
- 9.2 Quais modelos foram o quê 23
- 9.3 Os dois modelos 23
- 9.4 Treino, inferência e atualização de histórico 24
- 9.5 Artefatos 24
- 9.6 Separação dos dados e vazamento 25

10 Explorar previsões existentes 26

11 Interface e sessão 27
- 11.1 Áreas 27
- 11.2 Controles de uma análise 27
- 11.3 Sessão 27
- 11.4 O que dispara processamento 28

12 Usar novos datasets 29
12.1 Transações: hismall_v1 (formato do IBM AML) 29
12.2 Transações: transacao_hismall_v1 (em português) 29
12.3 Medições: rede_v1 29
12.4 Histórico anterior 30
12.5 Duplicidade e registros inválidos 30
12.6 Limites 30
12.7 Entrada ou previsões? 30
12.8 Erros e correções 31
12.9 Rótulos e métricas 31

13 Eventos, histórico incremental e recuperação 32
13.1 Formas de processar 32
13.2 Quando chega uma transação 32
13.3 Fechamento do minuto e atraso 32
13.4 Duplicatas e conflitos 33
13.5 Registro, instantâneo e projeções 33
13.6 O que acontece numa falha 33
13.7 Garantias 34
13.8 Análises de dataset interrompidas 34
13.9 Rede + transações 34

14 Testes automatizados 35

15 Resultados e limitações 36
15.1 Como ler as métricas 36
15.2 Rede 36
15.3 Lavagem 37
15.4 Dados e rótulos 37
15.5 Reuso do teste 37
15.6 Desempenho computacional 38
15.7 Limitações principais 38
15.8 Próximos passos de maior valor 39

16 Referência técnica e reprodução 40
16.1 Instalação 40
16.2 Comandos 40
16.3 Fluxos para reproduzir 40
16.4 Arquivos 41
16.5 Verificações deste manual 41

17 Glossário 43

18 Referências 44

Como ler este manual. A Parte I é para quem nunca trabalhou com Machine Learning: explica o problema, os dados e como ler um resultado, e traz um tutorial completo. A Parte II traz os detalhes para manter o sistema: fórmulas, formatos, garantias, resultados e arquivos. Os termos são explicados no primeiro uso e reunidos no glossário (seção 17).

De onde vêm as afirmações. A fonte é o código atual. Cada resultado indica a origem:

Marca	Significado
Verificado agora	Executado em 06/11/2026, na versão documentada, para este manual ou na revisão que o antecede.
Evidência existente	Resultado salvo de uma execução anterior, com a data. O código correspondente não mudou desde então, salvo indicação.

Nenhum modelo foi retreinado para escrever este documento.

Parte I — Para entender o sistema

Explicação sem pré-requisitos de Machine Learning: o problema, os dados, o que acontece numa análise, como ler o resultado e um tutorial com dados inventados.

1 O que é o NodeWatch

1.1 O problema

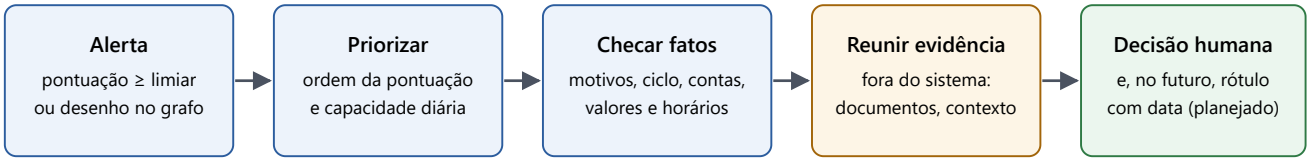
O NodeWatch é um MVP (*Minimum Viable Product*, produto mínimo viável) acadêmico que ajuda uma pessoa analista a decidir **o que investigar primeiro** em transações financeiras.

A ideia original vem da disciplina de Teoria dos Grafos. Um grafo é um conjunto de pontos ligados por setas: se cada conta é um ponto e cada transação é uma seta, certos desenhos chamam atenção. O dinheiro que sai de uma conta, passa por outras e volta à origem, por exemplo, é um desenho típico da lavagem de dinheiro.

Depois foi acrescentado um módulo de ML (*Machine Learning*, aprendizado de máquina). Nele, um programa aprende com exemplos em vez de seguir regras escritas à mão. São duas tarefas independentes:

- pontuar transações de um conjunto **sintético** de lavagem de dinheiro;
- prever o estado de uma rede de comunicação a partir de medições.

> **O NodeWatch não prova fraude.** Um alerta é um pedido de atenção, não um veredito. A decisão é sempre de uma pessoa, com outras evidências.



Azul: o que o NodeWatch faz. Âmbar e verde: trabalho da pessoa analista.

Figura 1 — Papel de um alerta numa investigação. O sistema entrega as três primeiras etapas.

1.2 Quatro coisas que não se confundem

Termo	O que significa aqui	O que **não** é
Anomalia de rede	Previsão de que a próxima medição de um caminho de rede estará em RISCO ou FALHA.	Não é indício de fraude. Não existe ligação verificada entre rede e transações.
Comportamento financeiro suspeito	Desenho no grafo (ciclo, grupo fortemente conectado, conta concentradora) ou fato conferível sobre uma transação.	Não é ilícito por si: folhas de pagamento e comércios também criam esses desenhos.
Previsão de lavagem	`score_lavagem` igual ou acima do limiar, aprendido em dados sintéticos de **lavagem de dinheiro**.	Não é probabilidade calibrada, não é fraude confirmada, e lavagem não representa todos os tipos de fraude.
Fraude confirmada	Conclusão de uma investigação humana, com evidência e data.	Nenhum dado do projeto tem esse rótulo. Nenhum componente produz essa conclusão.

1.3 O que existe hoje

Situação na versão documentada:

Componente	Situação	Observação
Análise de grafos pela linha de comando (ciclos, SCC, centralidade)	Implementado e verificado	Calcula a partir de um CSV. Tem defeitos conhecidos abertos (seção 8.7).

Componente	Situação	Observação
Painel **Grafos**	Implementado, **demonstração estática**	Mostra resultados gravados no HTML das 16 transações de exemplo. Não recebe arquivo.
Sentinel AI (chat)	Implementado; **não verificado agora**	Exige chave de um serviço externo, ausente nesta máquina. Verificado só que, sem chave, responde HTTP 503 com a mensagem certa.
Detector de fan-out e fan-in	Implementado, verificado por testes; **fora** da CLI e do painel	Usado por testes e por `scripts/benchmark_fan.py`.
ML `estado_rede` e `lavagem` (treino, avaliação, inferência)	Implementado e verificado	Lavagem medida só em dados sintéticos.
Explorar previsões (tabelas, filtros, gráficos, exportação)	Implementado e verificado	Abre CSVs de previsões já calculadas.
Analisar dataset (arquivo novo, modelo salvo)	Implementado e verificado	Testado pela interface com arquivos fora dos exemplos.
Sessões de uso da interface	Implementado e verificado	Controle de uso, não é autenticação.
Eventos: API com aceitação durável, replay, recuperação, bloqueio	Implementado e verificado com queda real e falhas injetadas	Só demonstração local; **não há fonte ao vivo conectada**.
Queda de energia ou do sistema operacional	**Verificação pendente**	O código chama `fsync`, mas o cenário não foi executado.
Aba oculta em navegadores além do Chrome	**Verificação pendente**	Testado por 7 min no Chrome headless.
Capacidade HTTP sob carga concorrente	**Verificação pendente**	Medido um pedido por vez.
Integração técnica rede ↔ transação	Implementado, verificado em **simulação**	Dados sintéticos; não comprova relação nenhuma.
Modelo de fusão rede + transação	**Incompleto, bloqueado no código**	Treinar falha de propósito e lista o que falta.
Extrator de atributos de rede a partir de telemetria bruta (`rede_v2`)	**Planejado**	Depende da referência p95/p99 por fluxo, não documentada.
XGBoost	Avaliado por auditoria externa; **não implementado**	Não está no código nem nas dependências.
Autenticação de usuários	**Não existe**	O servidor é feito para rodar em `127.0.0.1`.

2 Que dados o sistema recebe

Dado	O que é	Quem usa
Transações para grafos	CSV simples: `step,type,amount,nameOrig,nameDest,isFraud`	Análise de grafos pela CLI
Transações com banco, moeda e data	Formato do IBM AML ou o mesmo em português (seção 12)	Modelo de lavagem
Medições de rede preparadas	CSV com 21 atributos já calculados (`rede_v1`)	Modelo de rede
CSV de previsões	Saída já calculada por uma análise anterior	Só para explorar; não gera previsões novas
Vínculos	Qual transação ou sessão usa qual caminho de rede, com validade	Integração técnica; hoje só em simulação
Perguntas no chat	Texto digitado no painel Grafos	Sentinel AI

Dois conjuntos foram usados para treinar:

- **`dataset_final.csv`**: telemetria de rede do material da disciplina, de 28/09 a 05/10/2026, com 333.954 medições de 135 caminhos.
- **IBM AML HI-Small**: 5.078.345 transações **sintéticas** de 01 a 18/09/2022, geradas por um simulador (Altman et al., 2023), com 5.177 marcadas como lavagem pelo próprio simulador. Não são transações bancárias reais.

Os dois conjuntos não têm nenhuma chave em comum e são de anos diferentes.

3 O que acontece numa análise

Exemplo: você tem um arquivo de transações e quer saber quais merecem atenção.

1. **Você abre a interface.** A página abre uma **sessão**, uma espécie de crachá que diz "há alguém usando". Nada é analisado.
2. **Você seleciona o arquivo e clica em Validar.** O servidor confere colunas, datas e valores, linha a linha. Linhas ruins são recusadas com o motivo; nada é preenchido. Ainda não há previsão.
3. **Você clica em Analisar dataset.** Só agora o trabalho começa.
4. **O sistema põe as transações em ordem de tempo** e cria um histórico vazio só desta análise.
5. **Para cada minuto, calcula atributos.** Atributos são números que descrevem o contexto de uma transação: quanto essa conta enviou nas últimas 24 horas, se o destino é novo, se o valor foge do costume dela. Só entra o que aconteceu **antes** daquele minuto.
6. **O modelo dá uma nota.** Um modelo já treinado recebe os 49 atributos e devolve um número entre 0 e 1, o score. Nada é treinado aqui.
7. **O sistema compara a nota com um limiar.** Se `score_lavagem ≥ 0,0910`, a transação vira **alerta**, com motivos conferíveis.
8. **Atualiza o histórico das contas** e segue para o minuto seguinte. Atualizar o histórico não é treinar: o modelo não muda.
9. **Você consulta os resultados** em tabelas e gráficos e exporta o CSV. Filtrar não refaz nenhum cálculo.

3.1 Como o modelo chega a uma nota

O modelo escolhido nas duas tarefas é uma **Random Forest** (floresta aleatória): um conjunto de árvores de decisão. Uma árvore é uma sequência de perguntas sobre os atributos, como "o par origem→destino é novo?" e "enviou mais de X em 24 h?". Cada árvore aprendeu suas perguntas com uma parte diferente dos exemplos do treino. A nota final é a média das respostas de todas.

Isso é **aprendizado supervisionado**: o modelo aprendeu com exemplos cuja resposta era conhecida.

3.2 Como ler um resultado

O que você vê	Como ler
`score_lavagem` alto	Parecido com o que o simulador marcou como lavagem. Serve para **ordenar** a fila. Um score de 0,18 não quer dizer "18% de chance".
`alerta_lavagem = verdadeiro`	Passou do limiar. Vale olhar.
`motivos_verificaveis`	Fatos que você pode conferir, como "primeira transação entre origem e destino". **Não** explicam a decisão do modelo.
`historico_incompleto = verdadeiro`	Menos de 72 h de observação antes da transação. Os atributos estão subestimados.
Sem alerta	Não quer dizer "seguro". No teste oficial, 59% da lavagem sintética não gerou alerta.
`score_alerta_rede` e `alerta_rede`	Estado previsto da **próxima medição** de rede. Nada a ver com fraude.

3.3 Quais conclusões os dados permitem

Permitem:

- dizer que, **nos dados sintéticos do HI-Small**, o modelo ordena a lavagem muito melhor que regras simples;
- dizer que, **na telemetria avaliada**, o modelo de rede gera menos falsos alertas que repetir o estado atual;
- conferir ciclos e grupos num arquivo de transações.

Ainda não permitem:

- afirmar desempenho em transações reais de um banco ou em outra população;
- afirmar que uma anomalia de rede ajuda a detectar fraude: isso nunca foi medido;
- detectar fraude em geral: o rótulo financeiro é só **lavagem sintética**;
- tratar uma pequena diferença de métrica como melhoria comprovada (seção 15.5).

4 Tutorial completo com dados inventados

> **Tudo aqui é inventado.** Contas, bancos, valores e datas foram criados à mão em `docs/exemplos/transacoes_inventadas.csv` só para ilustrar o formato e a leitura. Os scores abaixo não dizem nada sobre o desempenho do modelo.

Verificado agora: as saídas abaixo são as reais, com o modelo salvo.

Passo 1 — Instalar e abrir. Comandos na seção 16.1. Depois:

```
python src/sentinel_ai.py
```

Abra `http://127.0.0.1:5000/#ml/analisar`. A faixa "Sessão da interface" deve mostrar **ativa**. Nada começou.

Passo 2 — O arquivo. A história inventada: a conta `MERCADO1` faz pagamentos pequenos e regulares. No dia 13, recebe 48.000 de `ORIGEM9` e, em minutos, repassa quase tudo a duas contas novas, com recebimento em outra moeda. As últimas três linhas são erros de propósito.

```
id_transacao,timestamp,banco_origem,conta_origem,banco_destino,conta_destino,valor_pago,moeda_pagamento,
valor_recebido,moeda_recebimento,formato
tx-001,2025-03-10T09:00:00Z,301,MERCADO1,302,FORNEC01,120.5,US Dollar,120.5,US Dollar,ACH
...
tx-009,2025-03-13T10:00:00Z,309,ORIGEM9,301,MERCADO1,48000.0,US Dollar,48000.0,US Dollar,ACH
tx-010,2025-03-13T10:05:00Z,301,MERCADO1,310,NOVA0001,23500.0,US Dollar,23500.0,Euro,ACH
tx-011,2025-03-13T10:06:00Z,301,MERCADO1,311,NOVA0002,23400.0,US Dollar,23400.0,Euro,ACH
tx-012,2025-03-13T10:07:00Z,310,NOVA0001,301,MERCADO1,900.0,US Dollar,900.0,US Dollar,ACH
tx-013,ontem,301,MERCADO1,302,FORNEC01,10.00,US Dollar,10.00,US Dollar,ACH
tx-014,2025-03-13T11:00:00Z,301,MERCADO1,302,FORNEC01,-5.00,US Dollar,5.00,US Dollar,ACH
tx-001,2025-03-10T09:00:00Z,301,MERCADO1,302,FORNEC01,120.5,US Dollar,120.5,US Dollar,ACH
```

Passo 3 — Validar. Selecione o arquivo e clique em **Validar arquivo**. O cartão mostra:

Campo	Valor	Leitura
Formato	`transacao_hismall_v1`	Reconhecido pelas colunas, não pelo nome.
Linhas	15 lidas, 12 válidas, 3 recusadas	O arquivo tem 15 linhas de dados.
Recusas	data/hora inválida (1), valor negativo (1), `id_transacao` repetido (1)	Nada é corrigido nem preenchido.
Período	10/03/2025 a 13/03/2025	
Rótulos	sem rótulos	Métricas de acerto ficarão indisponíveis.
Processadas	0	Validar não gera previsões.

Passo 4 — Analisar. Clique em **Analisar dataset**. A barra mostra o progresso. Em um arquivo grande, **Pausar** e **Cancelar** valem no fim do bloco em andamento.

Passo 5 — Ler o resultado.

Transação	Quando	Origem → destino	Valor	Score	Alerta	Hist. incompleto
tx-001	10/03 09:00	MERCADO1 → FORNEC01	120,50	0,0003	não	sim
tx-005	12/03 09:00	MERCADO1 → FORNEC01	110,00	0,0015	não	sim

Transação	Quando	Origem → destino	Valor	Score	Alerta	Hist. incompleto
tx-006	12/03 09:00	CLIENTE7 → MERCADO1	45,90	0,00001	não	sim
tx-008	13/03 09:00	MERCADO1 → FORNEC01	125,60	0,0004	não	não
tx-009	13/03 10:00	ORIGEM9 → MERCADO1	48.000,00	0,0055	não	não
tx-010	13/03 10:05	MERCADO1 → NOVA0001	23.500,00	0,0172	não	não
tx-011	13/03 10:06	MERCADO1 → NOVA0002	23.400,00	0,0231	não	não
tx-012	13/03 10:07	NOVA0001 → MERCADO1	900,00	0,0159	não	não

(As demais linhas têm scores de 0,0009 a 0,0042, sem alerta.)

O que dá para aprender com isso:

1. **O repasse aumentou a nota, mas não houve alerta.** A nota subiu de cerca de 0,001 para 0,023, abaixo do limiar de 0,0910. Sem alerta não quer dizer "seguro".
2. **O modelo reage a padrões do conjunto em que foi treinado.** Uma história que parece suspeita para uma pessoa pode não se parecer com o que o simulador gerou. E o inverso também vale.
3. **tx-005 e tx-006 estão no mesmo minuto.** Nenhuma enxerga a outra, por construção.
4. **Sem rótulos**, a tela diz: "precisão, recall e demais métricas supervisionadas ficam indisponíveis". Sem saber a resposta certa, não há como calcular acerto.
5. **Sem histórico anterior**, as 7 primeiras linhas saem com histórico incompleto, porque a observação começou há menos de 72 h. Se você tiver transações anteriores, informe-as (seção 12.4).

Passo 6 — Consultar e exportar. Clique em **Abrir resultados**: tabela, filtros e gráficos usam o CSV gerado, sem nova inferência. **Exportar CSV** baixa as previsões.

Os arquivos ficam em `artefatos_ml/analises/`, e a pasta `artefatos_ml/analises/.jobs/<id>/` guarda a entrada, o estado e o progresso. A interface não oferece exclusão: para apagar, remova os arquivos com o servidor parado.

Parte II — Referência técnica

Arquitetura, cada análise, Machine Learning de ponta a ponta, formatos, sessão, eventos, resultados, limitações e arquivos.

5 Arquitetura

5.1 Componentes

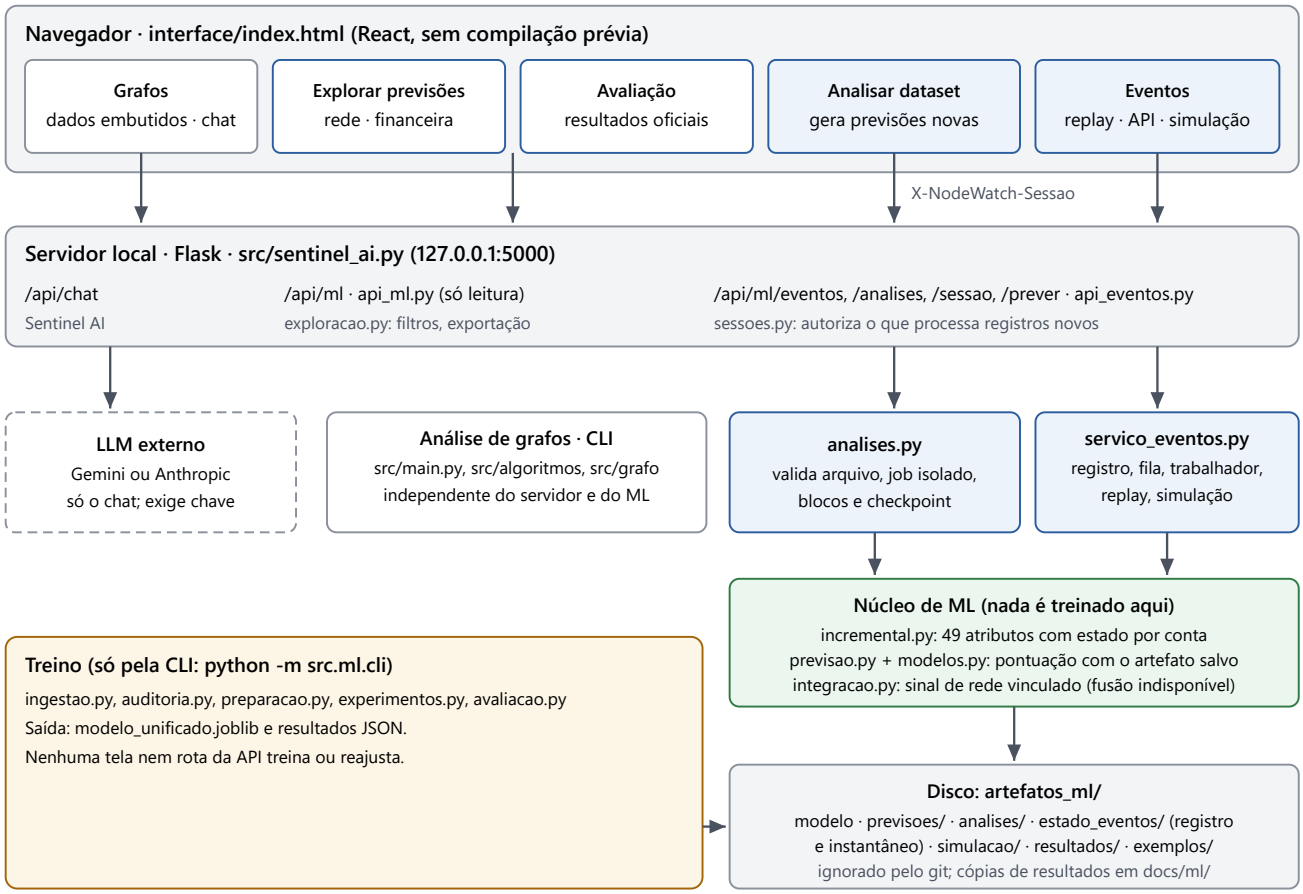


Figura 2 — Componentes existentes. Azul: gera previsões novas. Verde: núcleo de ML. Âmbar: treino, só pela CLI. Tracejado: serviço externo opcional.

Componente	Onde	Papel
Interface	`interface/index.html`	Uma página React, sem etapa de compilação. Seções Grafos e Machine Learning.
Servidor	`src/sentinel_ai.py` (Flask)	Serve a página, o chat e os blueprints.
API de exploração	`src/api_ml.py`, `src/ml/exploracao.py`	Lê previsões e resultados; importa CSV de previsões só em memória.
API de processamento	`src/api_eventos.py`	Sessões, eventos, replay, análises e previsão sob demanda.
Sessões	`src/ml/sessoes.py`	Quem autoriza processar registros novos.
Importação e validação	`src/ml/analises.py`, `src/ml/eventos.py`, `src/ml/esquemas.py`, `src/ml/ingestao.py`	Contratos, leitura e recusa com motivo.
Preparação	`src/ml/preparacao.py` (lote), `src/ml/incremental.py` (estado)	Atributos financeiros; matriz de rede.
Grafos	`src/main.py`, `src/grafo/`, `src/algoritmos/`, `src/leitura/`	CLI independente do servidor e do ML.
ML	`src/ml/modelos.py`, `experimentos.py`, `previsao.py`, `avaliacao.py`	Treino, avaliação e inferência.

Componente	Onde	Papel
Eventos	`src/ml/servico_eventos.py`, `registro_eventos.py`, `replay.py`, `simulacao.py`	Registro durável, fila, recuperação, replay, laboratório.
Armazenamento	`artefatos_ml/` (ignorado pelo git)	Modelo, previsões, análises, estado de eventos. Não há banco de dados.
Relatórios	`docs/ml/` e `src/ml/relatorio.py`	Resultados versionados e relatórios gerados.

5.2 Caminho dos dados

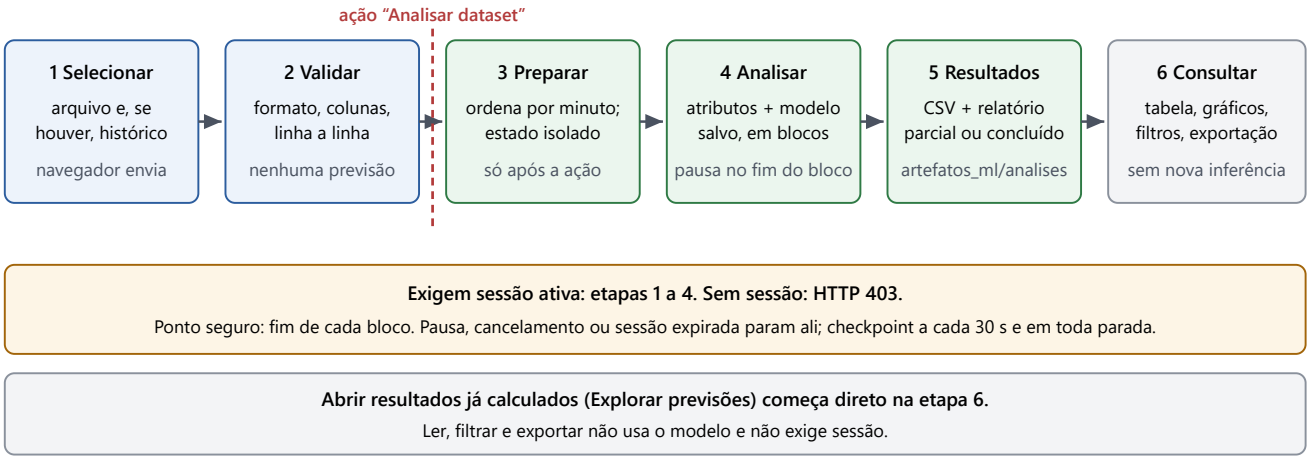


Figura 3 — Da seleção do dataset à consulta. A ação explícita separa validar de analisar.

Executar uma análise nova (área Analisar dataset, Eventos ou CLI `prever`) usa o modelo e gera um CSV. **Abrir resultados calculados** (Análise de rede, Análise financeira, Avaliação) só lê arquivos: não usa o modelo e não precisa de sessão.

5.3 O que roda onde

Onde	O que acontece
Navegador	Desenho das telas; consultas periódicas (status a cada 2 s, por padrão); renovação da sessão. Na seção Grafos, todo o cálculo já está gravado no HTML.
Servidor local	Validação, atributos, modelo, filtros e resumos, escrita de arquivos, chamada ao LLM.
Serviços externos	Só o Sentinel AI: envia a pergunta e o contexto do painel ao Google Gemini (padrão) ou à Anthropic.

Internet e configuração (verificado no código):

Item	Necessário para
Nada de internet	Grafos, ML, análises e eventos. React e Babel estão em `interface/assets/vendor`. Se esses arquivos faltarem, a página tenta o `unpkg.com`. As fontes vêm do Google Fonts, mas a página funciona sem elas.
Chave `GEMINI_API_KEY` (ou Anthropic) em `.env`	Só o chat. Sem ela, `/api/chat` responde 503. `start_presentation.ps1/.sh` exigem a chave; para usar só o ML, rode `python src/sentinel_ai.py`.
`ml_config.local.toml`	Treinar, avaliar e usar o histórico do HI-Small no replay. Analisar dataset não precisa dele.
`artefatos_ml/modelo_unificado.joblib`	Qualquer previsão. Ignorado pelo git: gere com `treinar`.

5.4 Sentinel AI

É um assistente de conversa no painel **Grafos**. Recebe a pergunta e um retrato do painel: ciclos, estatísticas, transações de exemplo, dados dos gráficos, SCC, centralidade e um catálogo da interface. Detalhes em `docs/SENTINEL_AI.md`.

	Sentinel AI	Modelos do NodeWatch
Tipo	LLM (*Large Language Model*) externo, geração de texto	Random Forest local, classificação
Saída	Texto explicativo	Score, classe e alerta, reproduzíveis
Dados que usa	Pergunta e estado do painel Grafos. **Não** recebe as previsões de ML	Atributos numéricos
Internet	Sim	Não

O chat explica; não detecta nada e não altera nenhum cálculo. **Atenção:** o que estiver no contexto é enviado ao provedor externo.

6 Análises financeiras por grafos

Verificado agora: a CLI com o exemplo abaixo. **O código não mudou** desde a auditoria de 02/11/2026 (`git diff` vazio em `src/algoritmos`, `src/grafo`, `src/leitura` e `src/main.py`).

Objetivo: encontrar desenhos suspeitos na estrutura das transações. São regras fixas, sem aprendizado: a mesma entrada gera a mesma saída.

Entrada: CSV com `nameOrig`, `nameDest` e `amount` (obrigatórias) e `type`, `step` e `isFraud` (opcionais).
Representação: multigrafo direcionado ponderado (`src/grafo/graph.py`): cada conta é um vértice, cada transação é uma aresta da origem ao destino, com peso igual ao valor. Pode haver várias arestas entre o mesmo par.

> **A interface não calcula grafos.** A seção Grafos mostra resultados pré-gravados das 16 transações de `dados/exemplo_transacoes.csv`, com a faixa "DEMONSTRAÇÃO ESTÁTICA". Para analisar outro arquivo, use a CLI. *Analisar dataset* não faz análise de grafos.

6.1 Ciclos

`find_cycles` (`src/algoritmos/cycle_detection.py`) limita a busca às arestas dentro de um mesmo SCC, faz uma DFS (*Depth-First Search*, busca em profundidade) iterativa a partir de cada vértice e registra os ciclos simples, em que nenhuma conta se repete.

- **Categoria:** ANOMALIA para laço da conta nela mesma; CICLO nos demais casos.
- **Prioridade:** pelo tipo de maior risco no caminho: TRANSFER = ALTO, CASH_OUT = MÉDIO-ALTO, PAYMENT = MÉDIO, CASH_IN ou DEBIT = BAIXO.
- **Saída:** caminho, valor, "perda" (primeira aresta menos a última) e intermediárias.
- **Limitações:** ignora a ordem no tempo, então um ciclo pode ser "impossível" no tempo. Enumerar todos os ciclos tem pior caso **exponencial**.

6.2 Componentes fortemente conectados (SCC)

`find_scc` (`src/algoritmos/scc.py`) usa o algoritmo de Kosaraju, em duas DFS, com custo O(V + E). Um SCC (*Strongly Connected Component*) é um grupo em que toda conta alcança todas as outras. Grupos com mais de uma conta são marcados como suspeitos. **Limitação:** redes legítimas também formam esses grupos.

6.3 Centralidade e pontuação de risco

`compute_centrality` (`src/algoritmos/centralidade.py`):

```
risk_score = pontos do tipo mais enviado + 15 × (ciclos em que a conta aparece), com teto 100
pontos: TRANSFER 40 · CASH_OUT 30 · PAYMENT 15 · CASH_IN 10 · DEBIT 10 · não envia 0
```

`hub_type`: SUSPEITO (em algum ciclo); DISTRIBUIDOR (envia ≥ 3× o que recebe); COLETOR (envia ≤ ⅓); INTERMEDIÁRIO (grau total ≥ 4); NORMAL. **Limitação:** pesos escolhidos à mão, não calibrados com dados.

6.4 Fan-out e fan-in

`find_fan_patterns` (`src/algoritmos/fan_detection.py`) acha contas que enviam para muitas contas (fan-out) ou recebem de muitas (fan-in) numa janela de `step`: padrão de 10 contrapartes em 72 unidades de `step`. **Não está ligado à CLI nem ao painel**; é usado por testes e scripts.

6.5 Exemplo

```
python src/main.py --input dados/exemplo_transacoes.csv --scc --centralidade
```

Saída real, resumida:

```
Vértices (contas): 15 · Arestas (transações): 16
CICLO 1 [ALTO]: C011 -> C012 -> C013 -> C014 -> C011   valor 30.800   perda 600
CICLO 2 [ALTO]: C001 -> C002 -> C003 -> C001           valor 29.800   perda 200
CICLO 3 [ALTO]: C006 -> C007 -> C008 -> C006           valor  8.850   perda 100
Centralidade: as contas dos ciclos têm risk_score 55 (40 por TRANSFER + 15 por 1 ciclo), tipo SUSPEITO
```

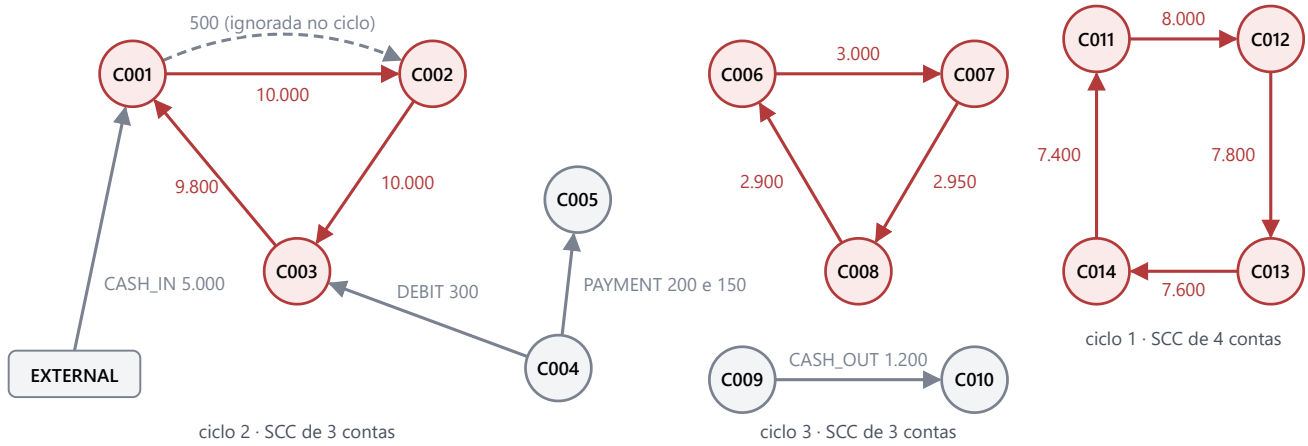


Figura 4 — Grafo do CSV de exemplo. Arestas vermelhas: ciclos. Entre C001 e C002 há duas transações paralelas (10.000 e 500).

O ciclo C001→C002→C003 vale 29.800, mas o volume do SCC é 30.300: o ciclo só conta a primeira das transações paralelas (defeito A3, seção 8.7). A CLI imprime "R$" e "tempo O(V + E)", mas o CSV não tem moeda, e a enumeração de ciclos pode ser exponencial.

`--export-json` grava o resultado em `dados/analises/` sem sobrescrever análises anteriores.

Em um recorte de 50 mil transações do HI-Small convertidas por `scripts/converter_ibm_aml.py`, SCC e ciclos mais fan-out/fan-in somados sinalizaram cerca de 35% das lavagens rotuladas. **Evidência existente**, em `docs/melhorias-e-limitacoes.md`. O conversor descarta a moeda.

7 Telemetria de rede

Objetivo: prever o estado da próxima medição de um caminho de rede.

Dados: cada linha é uma medição de um fluxo, um par sonda→âncora (`id_fluxo = probe_id_anchor_id`), a cada 240 s em mediana. **Unidade temporal do alvo:** `alvo` é o estado da **próxima medição do mesmo fluxo**, não do instante atual.

Medição bruta ou preparada? Só preparada. O sistema exige os 21 atributos prontos. Telemetria bruta é recusada com o motivo (**verificado agora**: `rtt_ms` recusado por API e laboratório). As razões dividem o RTT (*Round-Trip Time*, tempo de ida e volta) pelo p95/p99 de referência de cada fluxo, e o período dessa referência não está documentado. Calcular uma por conta própria mudaria o significado dos atributos. Um extrator causal seria um esquema novo, `rede_v2`: **planejado**.

Grupo	Atributos	Significado
Medição	`perda_pct`, `rtt_ausente`, `delta_ttl_clip`, `ttl_reset`, `perdas_consecutivas`	Perda de pacotes; sem RTT; variação de TTL (*Time To Live*); perdas seguidas.
Razões	`razao_rtt_p95`, `razao_rtt_p99`, `razao_jitter_p95`, `amplitude_rtt_rel`	Acima de 1 = pior que o habitual do fluxo. −1 = sem RTT. Jitter é a variação do atraso.
Janelas (k = 3, 6, 12)	`perda_media_wk`, `rtt_p95_max_wk`, `jitter_p95_max_wk`, `n_rtt_acima_p95_wk`	Últimas k **medições** do fluxo, incluindo a atual. Contadas em linhas, não em tempo.
Identificação	`id_fluxo`, `anchor_id`, `probe_id`, `timestamp`	Obrigatórios; **nunca** viram preditores.
Opcionais	`classe_atual`, `alvo`, `split`	Fora dos preditores do modelo escolhido. `alvo` permite avaliação separada.

Classes: a auditoria descobriu a regra que gera o rótulo, reproduzindo `classe_atual` em 99,94% das linhas:

```
FALHA  se rtt_ausente = 1, ou razao_rtt_p99 > 1, ou perda ≥ 50%
RISCO  senão, se razao_rtt_p95 > 1, ou razao_jitter_p95 > 1, ou há perda
OK     nos demais casos
```

Portanto, a tarefa de ML é **antecipar uma regra** uma medição à frente.

Saídas: `classe_prevista` é a classe de maior probabilidade. `score_alerta_rede = P(RISCO) + P(FALHA)`, e `alerta_rede` é verdadeiro se ≥ 0,3173. As duas podem discordar.

Exemplo (inventado, verificado agora com o modelo real;
`docs/exemplos/medicoes_inventadas_rede.csv`):

Medição	Sinais	P(OK) / P(RISCO) / P(FALHA)	Classe	Score	Alerta
1	RTT normal	0,950 / 0,047 / 0,004	OK	0,050	não
2	RTT 48% acima do p95	0,483 / 0,061 / 0,456	OK	0,517	**sim**
3	RTT alto e 33% de perda	0,440 / 0,112 / 0,448	FALHA	0,560	**sim**

Na medição 2, a classe mais provável é OK, e mesmo assim há alerta: o modelo vê quase meio a meio entre continuar bem e falhar.

Limitações: quase não antecipa o início de um problema (4,5% dos inícios de evento). Em fluxos fora do treino, o ganho sobre repetir o estado atual quase some (seção 15.2). **Anomalia de rede não é fraude.**

8 Transações financeiras e lavagem

Objetivo: ordenar transações para que o que se parece com lavagem apareça primeiro. **Entrada:** seção 12. **Saída:** score, alerta e motivos.

8.1 Identidade das contas

Uma conta é `banco-conta`: o mesmo número em bancos diferentes são contas diferentes. Bancos precisam ser numéricos.

8.2 Janelas temporais

Cada janela é `[t - w, t)`, em minutos inteiros. O próprio minuto `t` fica de fora, porque o horário tem resolução de minuto e a ordem dentro dele não é confiável. Esse cuidado de só usar o passado se chama *point-in-time*.

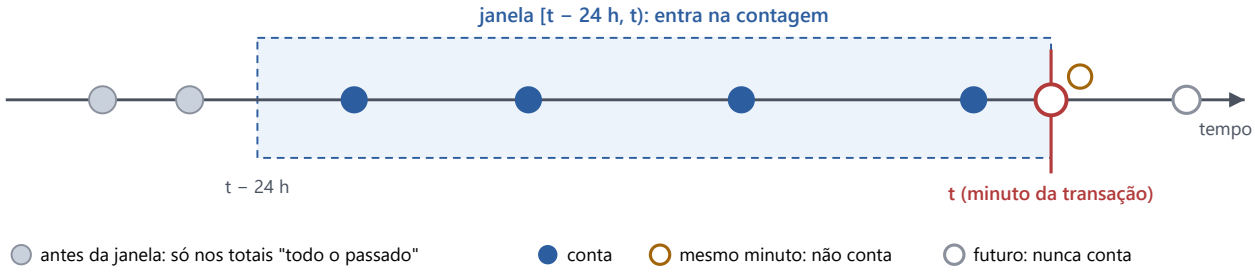


Figura 5 — Janela de 24 h para a transação no minuto t. O limite superior é aberto.

8.3 Os 49 atributos

Família	Atributos	Janela
Valor	`log_valor_usd` = log(1 + valor em USD); `sem_taxa_cambio`	transação
Envios da origem	`n_env_origem_6h/24h/72h`, `n_env_origem_total`, `soma_env_origem_usd_24h`, `min_desde_env_origem`	janela ou todo o passado
Valor atípico	`z_valor_origem`	todo o passado
Entrada e saída	`n_rec_origem_24h`, `soma_rec_origem_usd_24h`, `razao_saida_entrada_24h`, `min_desde_rec_origem`	24 h ou passado
Destino	`n_env_destino_24h`, `n_rec_destino_24h/72h`, `min_desde_rec_destino`	24 h, 72 h ou passado
Contrapartes	`par_novo`, `n_par_previas`, `dest_distintos_origem`, `orig_distintas_destino`	todo o passado
Da transação	`moeda_diferente`, `mesmo_banco`, `auto_transferencia`	transação
Falta de histórico	`sem_historico_env_origem`, `sem_historico_rec_origem`, `sem_historico_rec_destino`	todo o passado
Categorias	`formato_*` (7), `moeda_*` (15), em one-hot (uma coluna 0/1 por categoria do treino)	transação

Identificadores, horário, calendário e rótulos passados **não** são atributos. Arquivos de contas e de padrões também não.

8.4 Cálculos

Conferidos em `src/ml/preparacao.py` e `src/ml/incremental.py`.

Conversão para dólar. A taxa é a mediana de `recebido ÷ pago` nas transações do treino entre moedas diferentes, propagada entre pares. Foi aprendida no treino e não é reajustada. Moeda sem taxa: valor em USD ausente, `usd = 0` nas somas e `sem_taxa_cambio = 1`.

Valor atípico:

```
z = (x − média) / √(variância + 0,01),   x = log(1 + valor em USD)
z = 0 se a origem fez menos de 2 envios anteriores
```

Média e variância usam todos os envios anteriores da conta. O 0,01 evita valores enormes quando a conta enviou valores quase iguais: equivale a um desvio mínimo de 0,1 em log, cerca de 10% no valor.

Exemplo: envios anteriores com x = 7,0, 7,2 e 7,1 têm média 7,1 e variância 0,0067. Para um envio com x = 10: z = 2,9 / √0,0167 ≈ 22,5.

Razão saída/entrada:

```
razao_saida_entrada_24h = soma enviada em 24 h / (soma recebida em 24 h + 1)
```

Perto de 1: a conta repassa o que recebe. O +1 evita divisão por zero.

Tempo desde o último evento: minutos, com teto de 14.400 (10 dias). Sem histórico: 14.400 e o indicador `sem_historico_* = 1`.

Valores ausentes: só `log_valor_usd` pode ficar ausente. A Random Forest os recebe como estão. Na regressão logística, que foi candidata, são imputados pela mediana do treino.

8.5 Duas implementações dos mesmos atributos

	Lote: `atributos_financeiros`	Incremental: `EstadoFinanceiro`
Usado por	Treino, avaliação, CLI `prever`	Analisar dataset, Eventos
Como	Ordena e indexa tudo a cada chamada	Mantém estado por conta
Custo de 1 transação nova com 5 milhões de histórico	5,4 a 5,6 s	Frações de milissegundo amortizadas

Corrigido em 09/11/2026. Até então, o lote somava em prefixos acumulados sobre todo o histórico e perdia precisão: até 5,0% em `razao_saida_entrada_24h` no teste do HI-Small e 27% com valores na escala do HI-Large, contra a força bruta. Agora as somas acumuladas recomeçam em cada conta. Lote e incremental coincidem, e os dois ficam abaixo de 1e-6 de erro contra a força bruta. O modelo atual foi treinado com o lote antigo e não foi retreinado: recalculado com o lote corrigido, o teste do HI-Small dá score com diferença máxima de $8{\cdot}10^{-17}$ e **nenhum** dos 620 alertas muda de lado (`docs/ml/hi_large/RELATORIO_HI_LARGE.md`, seção 3.4).

8.6 Motivos verificáveis

Fatos simples, só nas linhas em alerta. Não explicam a decisão do modelo.

Motivo	Regra
Formato com taxa de lavagem no treino ≥ 5× a média	Na prática, só ACH

Motivo	Regra
Primeira transação entre origem e destino	`par_novo = 1`
Envios da origem em 24 h acima do p99 do treino	`n_env_origem_24h > 19.667`
Destino com mais origens que o p99	`orig_distintas_destino > 8`
Origem com mais destinos que o p99	`dest_distintos_origem > 14.230`
Valor atípico para a origem	`abs(z) > 3`
Origem recebeu fundos há menos de 60 min	`min_desde_rec_origem < 60`
Moedas de pagamento e recebimento diferentes	`moeda_diferente = 1`

Os dois limites muito altos (19.667 e 14.230) são dominados por poucas contas, por isso esses motivos quase nunca aparecem. Revisá-los é uma pendência.

8.7 Defeitos conhecidos, abertos

Defeito	Consequência
A1 — prioridade não entra na ordenação dos ciclos	Ordem de saída não segue a prioridade
A2 — `risk_score` depende da ordem interna de um conjunto em empate	Pode mudar entre execuções
A3 — arestas paralelas ignoradas no valor do ciclo	Valor do ciclo subestimado
A4 — `has_cycle` recursivo estoura em caminhos longos	`find_cycles`, iterativo, não é afetado
A5 — `add_edges_from` descarta `step`	Fan-out e fan-in sem tempo nesse caminho
A6 — `step = inf` derruba a leitura	`OverflowError`
A7 — `amount` inválido aceito; linhas sem conta descartadas sem aviso	Volumes distorcidos

9 Machine Learning de ponta a ponta

9.1 Biblioteca não é algoritmo

Peça	O que é	Papel
scikit-learn 1.9.1	Biblioteca com implementações de modelos	Fornece todos os modelos. Nenhum foi escrito à mão.
NumPy 2.5.4	Biblioteca de vetores, **não é um modelo**	Com ela foi escrito o motor de atributos (ordenação + busca binária + somas) e métricas próprias.
pandas, **pyarrow**, **joblib**	Tabelas, leitura de CSV, salvar objetos	Infraestrutura.

9.2 Quais modelos foram o quê

Algoritmo	Situação	Observação
Random Forest	**Escolhida** nas duas tarefas	Árvores independentes, média das respostas.
HistGradientBoosting	Implementado como candidato, avaliado, **não escolhido**	Árvores em sequência. Empate prático na rede.
Regressão logística	Implementada como candidata, avaliada, **não escolhida**	Apesar do nome, é **classificação supervisionada**: modela o log da chance como combinação linear dos atributos. AP de validação de 0,19 contra 0,50 na lavagem.
XGBoost	**Só avaliado** por auditoria externa, em scripts isolados	Não está no código. Candidato para confirmação futura (seção 15.5).
Baselines	Implementados	Classe majoritária, persistência, prevalência, taxa do formato: a régua mínima.
Redes neurais	Não usadas	

9.3 Os dois modelos

	`estado_rede`	`lavagem`
Problema	Classificação em 3 classes	Classificação binária, usada para ordenar
Variável prevista	`alvo`: OK, RISCO ou FALHA da próxima medição	`Is Laundering`: 0 ou 1 (verdade do simulador)
Aprendizado	Supervisionado	Supervisionado
Entrada	21 atributos de rede	49 atributos financeiros
Preparação	−1 vira ausente em 13 colunas; 3 indicadores `sem_rtt_wk`; remove constantes (`ttl_reset`): 23 colunas no modelo	Remove constantes. Só para a logística: imputa, `sinal(x)·log(1+abs(x))`, padroniza
Treino	241.359 linhas	Todos os 2.530 positivos + 20% dos negativos, com peso 5: 651.808 linhas
Candidatos	4 logísticas, 4 RF, 4 HGB	2 logísticas, 1 RF, 2 HGB
Critério de escolha	Maior macro-F1 na validação	Maior AP na validação
Escolhido	RF: 150 árvores, folha mínima 20, 50% da amostra, sem pesos	RF: 100 árvores, folha mínima 50, 50% da amostra
Score	`P(RISCO) + P(FALHA)`	Probabilidade da classe 1, **não calibrada**

	`estado_rede`	`lavagem`
Limiar	0,3173: máximo F1 de "não OK" na validação	0,0910: máximo F1 na validação
Versão	`estado_rede-20261102T083053Z`	`lavagem-20261102T083253Z`

Sem custos de erro fornecidos, o limiar usa máximo F1. Com custos ou capacidade de investigação, o critério poderia ser outro.

Existe ainda a variante `estado_rede__com_classe_atual`, só para comparação.

9.4 Treino, inferência e atualização de histórico

Etapa	O que muda	Quem faz
Treino	Parâmetros do modelo, câmbio, categorias, limiar	Só a CLI: `python -m src.ml.cli treinar`
Inferência	Nada no modelo: aplica-o a dados novos	CLI `prever`, Analisar dataset, Eventos, `/prever/rede`
Atualização do histórico	Só contagens e somas das contas **daquela** análise	`EstadoFinanceiro`, durante a inferência

Nenhuma tela, rota ou evento treina. Atualizar o estado de uma conta não muda o modelo.

9.5 Artefatos

- `artefatos_ml/modelo_unificado.joblib` (36,9 MB): um `ModeloUnificado` com *codificadores* por fonte de dados e uma *cabeça* por tarefa.
- `artefatos_ml/metadados_modelo.json`; cópias em `docs/ml/resultados/`.

"Unificado" quer dizer um arquivo e uma interface, **não** um modelo conjunto: cada cabeça foi treinada só com os próprios dados.

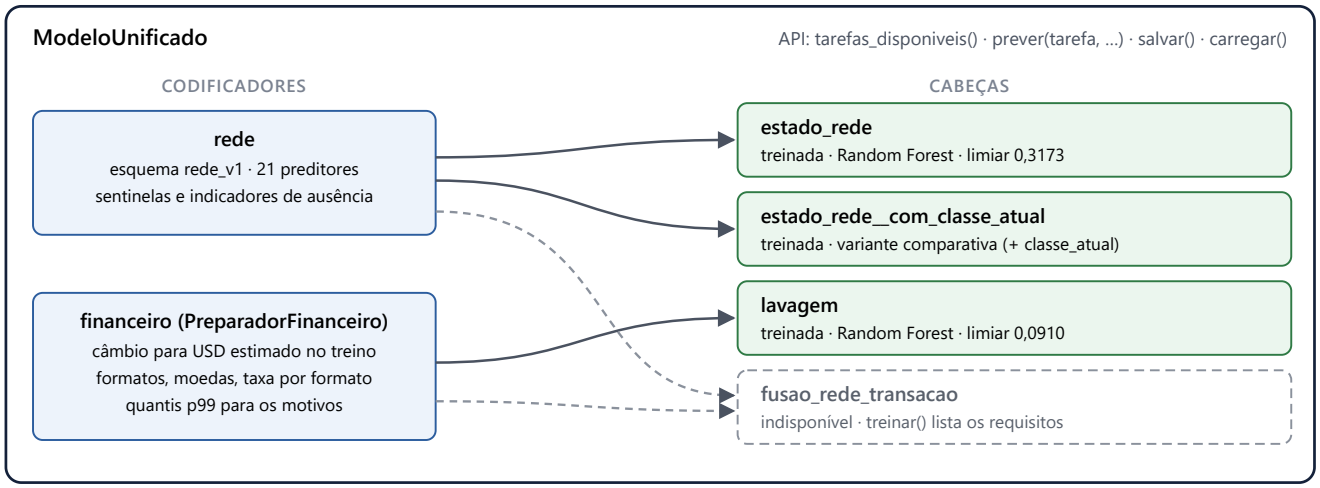


Figura 6 — Estrutura do ModeloUnificado. A ligação tracejada é a que a fusão exigiria e ainda não existe.

> **Segurança:** arquivos `joblib` e instantâneos `.pkl` executam código ao serem carregados. Carregue apenas os gerados por você.

Na inferência, o estimador usa `n_jobs = 1` em lotes de menos de 1.000 linhas, por uma cópia rasa que não altera o modelo compartilhado.

9.6 Separação dos dados e vazamento

Vazamento é usar informação que não estaria disponível na hora da previsão, o que torna a avaliação otimista demais.

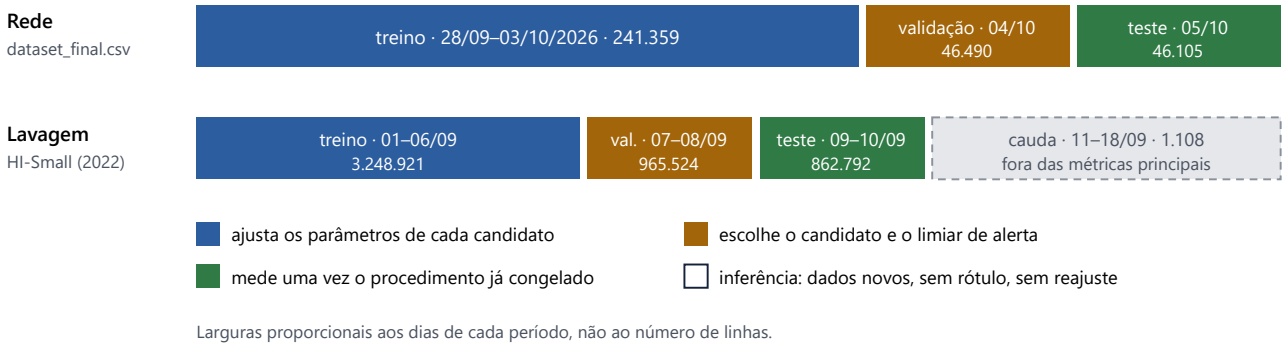


Figura 7 — Divisão temporal das duas tarefas.

Cuidado	Como é aplicado
Divisão pelo tempo	Treino antes de validação, antes de teste; lacuna mínima de 3.605 s na rede
Atributos só do passado	Janela `[t − w, t)`; teste: acrescentar futuro não muda o resultado
Ajustes só no treino	Imputação, escala, câmbio, categorias
Colunas proibidas	`alvo`, `split` e identificadores: `matriz_rede` recusa a execução
Arquivo de padrões	Nunca vira atributo: é a própria resposta
Escolhas	Modelo e limiar na validação; artefato congelado antes do teste

Desbalanceamento: na lavagem, 0,10% das transações são positivas; na rede, FALHA é 3,7%. Por isso a acurácia engana (seção 15.1), usa-se AP e macro-F1, e os negativos do treino são subamostrados com peso. Validação e teste mantêm a distribuição original.

10 Explorar previsões existentes

Áreas **Análise de rede** e **Análise financeira**. Lêem CSVs de previsões das pastas `artefatos_ml/{exemplos,previsoes,teste,analises}` e `docs/ml/exemplos`, ou importados (até 64 MB, 4 arquivos, só em memória).

- **Filtros:** período, contas, bancos, valor, moeda, formato, alerta, score, motivo e busca (financeiro); período, fluxo, âncora, sonda, classe, alerta e score (rede).
- **Consulta:** indicadores e gráficos usam todos os registros filtrados; a tabela é paginada (até 200 linhas por página).
- **Exportação:** registros filtrados, até 300.000. Acima disso, a tela explica e o CSV completo está em `artefatos_ml/`.
- **Selos:** arquivo completo, amostra, resultado parcial ou completude desconhecida.
- **Detalhes de um registro:** juntam a previsão com a linha de entrada quando ela é encontrada. **Em resultados de Analisar dataset, os atributos de entrada aparecem como indisponíveis**, porque a entrada fica em pasta própria (verificado agora).

Filtrar nunca roda o modelo. Rede e lavagem nunca são combinadas.

11 Interface e sessão

11.1 Áreas

Área	Endereço	Faz
Grafos	`#grafos`	Demonstração estática e chat
Visão geral	`#ml`	Resumo do arquivo selecionado e da avaliação oficial
Análise de rede / financeira	`#ml/rede`, `#ml/financeiro`	Explorar previsões
Avaliação dos modelos	`#ml/avaliacao`	Resultados oficiais
Analisar dataset	`#ml/analisar`	Dados novos
Eventos	`#ml/eventos`	Processamento, replay, API, CSV de rede, laboratório

11.2 Controles de uma análise

Situação	Significado	Ações
validado, aguardando	Validou; nada foi previsto	Analisar dataset, Cancelar
analisando	Em execução	Pausar, Cancelar
pausada	Parada com checkpoint; resultado parcial	Retomar, Cancelar, Abrir, Exportar
interrompida	O servidor caiu no meio	Retomar, Cancelar
cancelada	Definitiva; resultado parcial	Abrir, Exportar
erro	Falha; último checkpoint preservado	Tentar de novo, Cancelar
concluída	Arquivo inteiro	Abrir, Exportar

Uma análise roda por vez.

11.3 Sessão

Código: `src/ml/sessoes.py` e o gancho `useSessaoML` em `interface/index.html`, no `Dashboard`.

Evento	O que acontece
Criação	Ao carregar a página. Recarregar a mesma aba reaproveita a sessão.
Renovação	Pulso a cada 15 s e ao voltar a ficar visível.
Expiração	Sem pulso por **150 s**. Quem expirou não volta: a aba abre outra e avisa.
Encerrar sessão	Vale na hora; o trabalho dela para no próximo ponto seguro.
Várias abas	Cada uma tem a sua. Todas veem as análises e a responsável ("esta aba", "outra aba"). Qualquer aba ativa pode pausar ou cancelar; retomar transfere a responsabilidade.
Grafos ↔ ML	Não afeta a sessão. Verificado agora.

Aba em segundo plano ≠ sessão encerrada.

	Aba oculta ou minimizada	Sessão encerrada ou expirada
Pulso	Continua, mais espaçado	Parou
Trabalho	Continua	Para no próximo ponto seguro

	Aba oculta ou minimizada	Sessão encerrada ou expirada
Medido agora	Chrome: 15 s → 60 s depois de cerca de 80 s oculta, por 7 min; sessão ativa	Navegador morto, com prazo de demonstração de 5 s: parou em 6,0 s

Não há aviso confiável de fechamento de janela. **Consequência:** uma aba fechada continua "autorizando" por até 150 s, e o trabalho segue até o fim do bloco seguinte. Em navegadores ou modos de economia que espacem os temporizadores além de 150 s, a sessão expira e o trabalho pausa, com retomada explícita: é seguro, mas interrompe.

11.4 O que dispara processamento

Ação	Dispara?	Observado
Iniciar o servidor	Não	Trabalhador parado; nenhum replay
Abrir a interface	Não	Só cria a sessão
Consultar status	Não	Mas carrega o modelo na memória na primeira vez
Reabrir com trabalho parado	Não	Mostra e oferece retomada
Validar arquivo	Não gera previsões	Lê e confere o arquivo no servidor
Pedido à API sem sessão	Não	HTTP 403

Diferenças em relação a "só pela interface":

- A exigência de sessão vale para as **rotas HTTP**. A CLI (`python -m src.ml.cli prever`) e o uso do pacote em Python **não** verificam sessão: são caminhos diretos para quem tem acesso à máquina (verificado agora).
- A sessão é controle de uso, não autenticação: quem acessa a porta pode abrir uma.
- O produtor de exemplo usa uma sessão existente e não a renova. Encerrada a sessão, ele para.

12 Usar novos datasets

Vale qualquer arquivo que cumpra um contrato, sejam quais forem nome, caminho, período, contas ou quantidade de linhas. **Compatibilidade de formato não garante desempenho equivalente em outra população.**

12.1 Transações: `hismall_v1` (formato do IBM AML)

Mínimo válido (`docs/exemplos/transacoes_inventadas_formato_ibm.csv`, verificado agora):

```
Timestamp,From Bank,Account,To Bank,Account,Amount Received,Receiving Currency,Amount Paid,Payment
Currency,Payment Format
2025/03/10 09:00,301,MERCADO1,302,FORNEC01,120.50,US Dollar,120.50,US Dollar,ACH
```

12.2 Transações: `transacao_hismall_v1` (em português)

```
id_transacao,timestamp,banco_origem,conta_origem,banco_destino,conta_destino,valor_pago,moeda_pagamento,
valor_recebido,moeda_recebimento,formato
tx-001,2025-03-10T09:00:00Z,301,MERCADO1,302,FORNEC01,120.50,US Dollar,120.50,US Dollar,ACH
```

Campo	Obrigatório	Regra
Data	sim	IBM: `AAAA/MM/DD HH:MM`. Português: também ISO 8601 ou época em segundos. Sem fuso = UTC. Resolução de minuto.
Bancos	sim	Numéricos.
Contas	sim	Texto não vazio. Identidade: `banco-conta`. A 1ª `Account` é a origem; a 2ª, o destino.
Valores	sim	Números de 0 a 1e15, em unidades da moeda indicada, com ponto decimal.
Moedas	sim	Texto. As do treino: Australian Dollar, Bitcoin, Brazil Real, Canadian Dollar, Euro, Mexican Peso, Ruble, Rupee, Saudi Riyal, Shekel, Swiss Franc, UK Pound, US Dollar, Yen, Yuan.
Formato	sim	Texto. Os do treino: ACH, Bitcoin, Cash, Cheque, Credit Card, Reinvestment, Wire.
`id_transacao`	sim, em português	Único. No formato IBM, a identidade é a linha.
Rótulo	**não**	`Is Laundering` (IBM) ou `rotulo` (português): 0 ou 1.

Moedas e formatos fora do treino são aceitos e **sinalizados**. Moeda sem taxa não tem taxa inventada.

12.3 Medições: `rede_v1`

```
id_fluxo,anchor_id,probe_id,timestamp,perda_pct,rtt_ausente,razao_rtt_p95,razao_rtt_p99,razao_jitter_p95
,amplitude_rtt_rel,delta_ttl_clip,ttl_reset,perda_media_w3,rtt_p95_max_w3,jitter_p95_max_w3,n_rtt_acima_
p95_w3,perda_media_w6,rtt_p95_max_w6,jitter_p95_max_w6,n_rtt_acima_p95_w6,perda_media_w12,rtt_p95_max_w1
2,jitter_p95_max_w12,n_rtt_acima_p95_w12,perdas_consecutivas
9001_501,501,9001,1760000000,0,0,0.92,0.81,0.30,0.01,0,0,0,0.95,0.40,0,0,0.97,0.44,0,0,0.98,0.50,0,0
```

Valores inventados; faixas em `docs/ml/DICIONARIO_DADOS.md`. Com três medições assim, os indicadores de deriva não dizem nada: é pouca amostra.

12.4 Histórico anterior

Opcional, mas muda muito o resultado. O modelo foi treinado com contas que têm passado. **Verificado agora**, no mesmo arquivo (dia 03/09/2022 do HI-Small, 207.382 linhas, 391 positivos):

	Alertas	Precisão	Recall	AP
Sem histórico	1	100%	0,3%	0,143
Com 01–02/09 como histórico (1,87 milhão de transações)	203	57,6%	29,9%	0,394

Esses números mostram o efeito do histórico. **Não** são avaliação do modelo: 03/09 pertence ao período de treino.

Informe o histórico no segundo campo da tela, no mesmo formato de transações. Só entra o que é anterior ao primeiro minuto do dataset; o resto é contado como ignorado. **Isolamento:** cada análise tem estado próprio em `artefatos_ml/analises/.jobs/<id>/`. Nada vem de outro arquivo ou de outra análise. Duas análises não se contaminam (teste automático e demonstração).

12.5 Duplicidade e registros inválidos

Caso	O que acontece
Campo obrigatório vazio, data, banco ou valor inválidos	Linha recusada, com motivo e exemplos. Nada é preenchido.
`id_transacao` repetido	A primeira fica; a outra é recusada.
Chave `id_fluxo + timestamp` repetida	A primeira fica; a outra é recusada.
Arquivo fora de ordem	Ordenado por minuto, de forma estável. `linha_origem` guarda a posição original.
Nenhuma linha válida	Erro com os motivos mais frequentes.

12.6 Limites

Limite	Valor
Dataset	256 MB (CSV, ou ZIP com um CSV)
Histórico	512 MB
Importar previsões para explorar	64 MB
Exportação pela tela	300.000 registros
Análises simultâneas	1

Testado pela interface até 482.650 linhas de dataset e, como histórico, 5,08 milhões de linhas. O arquivo fica em memória durante a análise. O arquivo inteiro é analisado: nada é amostrado.

12.7 Entrada ou previsões?

	Dados de entrada	Arquivo de previsões
Tem	Transações ou medições	`score_lavagem`, `prob_OK` …
Onde usar	**Analisar dataset**	**Importar**, em Explorar previsões
Usa o modelo	Sim	Não
Em Analisar dataset	Analisado	Identificado e recusado, com a orientação

12.8 Erros e correções

Mensagens reais, verificadas agora:

Sintoma na tela	Causa	Correção
"É um arquivo de PREVISÕES já calculadas"	Enviou a saída de uma análise	Use Importar nas áreas de análise
"Serve para a análise de grafos, mas não para o modelo financeiro"	CSV `step,type,amount,nameOrig,nameDest`	Use a CLI de grafos. Para o modelo, são necessários bancos, moedas, valor recebido e data absoluta: dados que precisam vir da origem
"O mais próximo é transacao_hismall_v1; faltam: valor_recebido, moeda_recebimento"	Coluna ausente	Acrescente as colunas verdadeiras
"data/hora inválida"	`ontem` no lugar da data	Use ISO 8601
"valor pago ausente, negativo ou não numérico"	`-5.00`, ou `1.234,56`	Número ≥ 0 com ponto decimal
"telemetria bruta (...) não é aceita"	`rtt_ms` sem atributos	Envie os 21 atributos prontos

12.9 Rótulos e métricas

Rótulos são opcionais na inferência. O modelo só usa os atributos: os scores são idênticos com ou sem a coluna (teste automático).

Sem rótulos, há scores, alertas e estatísticas. Precisão e recall ficam **indisponíveis** porque comparam a previsão com a resposta certa, e ela não existe no arquivo. Com rótulos, a tela mostra uma avaliação separada no limiar oficial. Ela não ajusta nada e não substitui a avaliação oficial.

Indicadores de domínio são só os que dá para sustentar: moedas e formatos fora do treino, fração acima do p99 do treino (referência de cerca de 1%) e, na rede, PSI (*Population Stability Index*, mudança de distribuição). Não há medida de confiança.

13 Eventos, histórico incremental e recuperação

13.1 Formas de processar

Forma	Fonte	Rótulo
Lote	Arquivo inteiro de uma vez: CLI ou Analisar dataset	—
Replay histórico	Reenvia arquivos existentes como eventos	`replay_historico`
API de ingestão	`POST /api/ml/eventos`, de um produtor	`novo_evento`
Simulação	Laboratório, com transações e vínculos sintéticos	`simulacao`

> **Não há fonte ao vivo.** Reproduzir um CSV não é uma conexão real, e a API só recebe o que alguém enviar. Hoje isso é demonstração local.

13.2 Quando chega uma transação

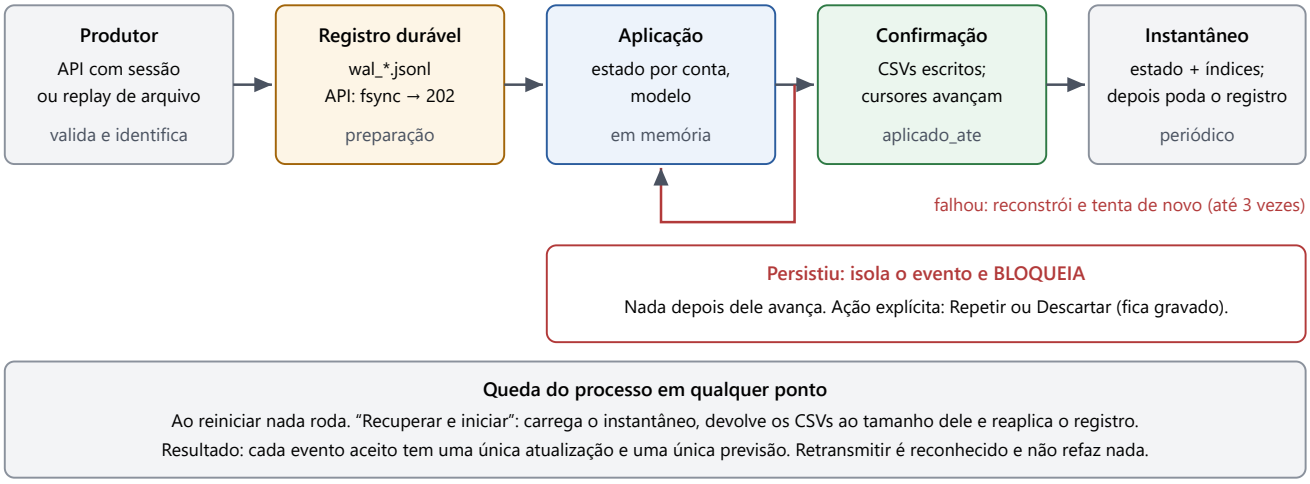


Figura 8 — Ciclo de um evento.

Exemplo (uma transação às 12:00:05, modo `novo_evento`):

1. A API valida, identifica (`tx:<id>`) e grava no registro durável, com `fsync`. Só então responde 202: é a **aceitação durável**.
2. O trabalhador põe a transação no minuto 12:00, que está **aberto**. Ela ainda não tem previsão.
3. Outra às 12:00:20 entra no mesmo minuto, mesmo depois de uma pausa.
4. O minuto **fecha**: as duas são pontuadas contra o estado anterior a 12:00 e só depois incorporadas.
5. A previsão vai para o CSV. Só então o cursor avança.

Ordem no tempo: o replay ordena o arquivo; a API processa na ordem de chegada. Dentro de um minuto ainda aberto, a ordem não importa, porque as transações não se enxergam.

13.3 Fechamento do minuto e atraso

Quem fecha	Quando	Vale para
Evento posterior	Chegou evento de minuto `m`: fecham os minutos anteriores a `m − atraso` (`NODEWATCH_ATRASO_MIN`, padrão 0)	Todos

Quem fecha	Quando	Vale para
Relógio	Passou do fim do minuto + atraso + 2 s de carência	Só `novo_evento`
Fim do replay financeiro	Último minuto	Replay
Fechar minutos abertos	Na hora, com confirmação	Todos

Ociosidade não fecha minutos. Um replay de 2022 nunca é fechado pelo relógio de hoje. Toda decisão fica gravada, para a reconstrução ser igual.

Transação de minuto já fechado é recusada como `atrasada`: não entra no estado nem é pontuada, porque mudaria atributos já emitidos. Fica registrada no CSV de recusas. Corrigi-la exigiria refazer o estado.

13.4 Duplicatas e conflitos

Caso	Resposta
Mesma identidade, mesmo conteúdo	`ja_aceitos`: retransmissão; nada é refeito
Mesma identidade, conteúdo diferente	Recusa `conflito`

Identidade: `tx:<id_transacao>`, `rede:<id_fluxo>@<timestamp>` ou hash do vínculo. O índice lembra até 1 milhão de identidades.

13.5 Registro, instantâneo e projeções

Peça	Onde	Papel
Registro durável	`artefatos_ml/estado_eventos/registro/wal_*.jsonl`	Todo evento aceito e todo comando
Instantâneo (ponto de recuperação)	`estado_eventos.pkl` + `.meta.json`	Estado completo até `aplicado_ate`. Gravado ao pausar replay, no fim dele, a cada 120 s ou 100 mil eventos com atividade, ao parar o servidor e por botão
CSVs de saída	`artefatos_ml/previsoes/eventos_*`	**Projeções**, reconstruíveis a partir dos dois

13.6 O que acontece numa falha

Cenário	Resultado	Evidência
Falha temporária na pontuação	Reconstrói e repete; uma previsão só	Teste
Falha na escrita, ou depois de escrita parcial	Saídas voltam ao tamanho certo; sem duplicar	Teste
Falha persistente	Isola o evento e **bloqueia**	Teste e interface
Falha ao gravar o instantâneo	Mantém o anterior e o registro	Teste
Queda do processo	Recuperação explícita; uma linha por evento	**Interface, com o processo morto à força**
Linha final incompleta no registro	Ignorada: não foi confirmada ao produtor	Teste
Sessão expira	Trabalhador para; eventos esperam no registro	Teste e interface
Instantâneo de outro modelo	Recusado na recuperação	Código

Eventos bloqueados. A tela mostra o evento, a causa e duas ações: **Repetir** ou **Descartar evento**. O descarte fica gravado e sobrevive ao reinício. Se a causa vier do fechamento de um minuto anterior, descartar o evento que o disparou não resolve.

Depois de reiniciar, nada roda. A área Eventos mostra o instantâneo e quantos eventos aceitos esperam. **Recuperar e iniciar** carrega o instantâneo, devolve os CSVs ao tamanho dele e reaplica o registro.

Demonstração real (verificada agora; saída em `docs/ml/evidencias/demo_queda.txt`): instantâneo, 3 eventos aceitos pela API, processo morto à força. Ao reiniciar: 3 eventos pendentes, trabalhador parado, nada muda ao abrir a interface. Depois da ação: 3 reaplicados, CSV com `demo-a` e `demo-b`, e `demo-c` no minuto aberto. Retransmitir os três: 0 aceitos e 3 já aceitos. `demo-a` com outro valor: `conflito`.

13.7 Garantias

Garantia	Vale para
Evento com resposta de aceito não some numa queda do processo	API
Uma atualização lógica e uma previsão por evento, depois de recuperar	API e replay
Nada confirmado além de um evento bloqueado	API e replay
Replay retoma pelo cursor, sem fsync por evento: a fonte é o arquivo	Replay

Não garantido ou não testado: queda do sistema operacional ou de energia; perda do disco; retransmissão depois de mais de 1 milhão de identidades (ainda recusada como atrasada, se o minuto fechou).

13.8 Análises de dataset interrompidas

Usam checkpoint, não o registro: a fonte é o arquivo. Pontos seguros são o fim de cada bloco (20.000 linhas, alinhado ao minuto). Na retomada, a saída volta ao tamanho do último checkpoint (a cada 30 s e em toda parada) e o restante é refeito. **Verificado agora:** pausa e retomada com 207.382 linhas únicas; navegador morto seguido de retomada, com 482.650 processadas.

13.9 Rede + transações

Situação	Estado	O que significa
Vínculo verificável	**Não existe**	Nenhum dado real liga transação a fluxo
Integração técnica	Pronta	Vínculos validados; sinal só se disponível na decisão (idade ≤ 480 s, vínculo vigente e já declarado, modelo treinado antes)
Demonstração simulada	Pronta	8 casos e 5 recusas conferem. Transações e vínculos são sintéticos
Modelo de fusão validado	**Não existe**	Treinar falha e lista o que falta

Compartilhar uma interface não comprova que as fontes estão relacionadas. Em uma previsão, `sinais_utilizados` continua `financeiro`: o sinal vinculado aparece ao lado, sem combinar. Uma conta bancária não é chave técnica. O que falta está em `docs/ml/CONTRATO_INTEGRACAO.md` e `docs/ml/CONTRATO_COLETA_EVENTOS.md`.

14 Testes automatizados

Verificado agora: a contagem está na seção 16.5.

Testes verificam se o código faz o que promete: contratos, ausência de vazamento, determinismo, equivalência com a referência, recuperação. **Não medem qualidade preditiva**, que vem da avaliação em períodos separados. Eles também não pegam os defeitos A1 a A4.

Arquivo	Verifica
`testes/ml/test_rede.py`, `test_financeiro.py`	Colunas proibidas, validação, inferência sem rótulos, atributos sem futuro
`testes/ml/test_referencia_financeira.py`	Lote igual à força bruta; previsões simultâneas
`testes/ml/test_incremental.py`	Incremental igual a lote e força bruta; bordas de janela; instantâneo
`testes/ml/test_eventos.py`, `test_confiabilidade_eventos.py`	Fila, replay, reinício, falhas injetadas, relógio
`testes/ml/test_analises.py`	Formatos, isolamento, rótulos, pausa, cancelamento, expiração, queda
`testes/ml/test_exploracao.py`, `testes/test_api_ml.py`, `test_api_eventos.py`	Filtros, exportação, rotas, recusa sem sessão
`testes/test_cycle_detection.py`, `test_scc.py`, `test_centralidade.py`, `test_exportador.py`, `test_fan_detection.py`, `test_escala.py`	Grafos

15 Resultados e limitações

Origem: `docs/ml/resultados/*.json` e `docs/ml/RELATORIO_ML.md`, execução de **02/11/2026**, artefatos `estado_rede-20261102T083053Z` e `lavagem-20261102T083253Z`. **Evidência existente**. Conferidos agora contra os JSONs.

15.1 Como ler as métricas

VP = verdadeiros positivos; FP = falsos positivos; FN = falsos negativos.

Métrica	Definição	Leitura
Precisão	VP ÷ (VP + FP)	Dos alertas, quantos estavam certos
Recall	VP ÷ (VP + FN)	Dos casos reais, quantos foram achados
F1	2 × P × R ÷ (P + R)	Equilíbrio entre os dois
Macro-F1	Média simples do F1 de cada classe	FALHA pesa igual a OK
AP (*Average Precision*)	Área sob a curva precisão × recall	Qualidade da ordenação, sem limiar. Referência: a prevalência (0,0011)
Matriz de confusão	Real × previsto	Quais erros, não só quantos
Recall@k	Fração achada entre as k maiores notas	Equipe que investiga k casos por dia

	Lavagem	Rede
Falso positivo	Transação normal investigada: custa tempo da equipe e incomoda quem é investigado	Alerta de um fluxo que seguiu OK: ruído operacional
Falso negativo	Lavagem sem alerta: não é investigada	Problema não avisado

Acurácia engana: prever sempre "não lavagem" dá 99,89% de acurácia e AP de 0,0011.

15.2 Rede

Teste: 05/10/2026, 46.105 medições, artefato congelado.

Referência	Macro-F1	Acurácia	Recall RISCO	Recall FALHA
Classe majoritária	0,311	0,873	0,000	0,000
Persistência (repete o estado atual)	0,711	0,894	0,507	0,681
Modelo escolhido	**0,750**	0,928	0,418	0,697

Matriz de confusão do modelo:

Real \ previsto	OK	RISCO	FALHA
OK	39.925	201	124
RISCO	2.400	1.856	184
FALHA	273	156	986

Medida	Persistência	Modelo
Alertas	5.861	4.621

Medida	Persistência	Modelo
Corretos / falsos	3.623 / 2.238	3.674 / 947
Falsos por fluxo-hora	0,73	0,31
Inícios de evento antecipados (2.229)	0%	4,5%
Macro-F1 em fluxos inéditos	0,674	0,681 ± 0,073

Leitura: o ganho vem de menos falsos alertas. O recall de RISCO cai. Quase não antecipa o início de um problema. Em fluxos fora do treino, a vantagem praticamente some. Validação: macro-F1 0,7628 (HGB 0,7618, empate prático).

15.3 Lavagem

Teste: 09–10/09/2022, 862.792 transações sintéticas, 956 de lavagem.

Referência	AP	Precisão	Recall	F1	VP	FP	FN
Prevalência	0,0011	0,001	1,000	0,002	956	861.836	0
Taxa do formato	0,0064	0,007	0,872	0,014	834	118.361	122
Modelo escolhido	**0,4640**	0,627	0,407	0,494	389	231	567

Dia	Transações	Lavagem	Recall@100	Recall@1000	Recall@5000
09/09/2022	654.467	514	0,18	0,54	0,71
10/09/2022	208.325	442	0,21	0,62	0,83

Por grupo: tipologias com recall de 0,55 a 0,72; **positivos sem padrão conhecido (39% do teste): 0,02**; tentativas iniciadas no próprio teste: 0,52; tentativas já iniciadas antes: 0,73 (otimista, pois o modelo viu o começo do esquema). AP de validação: 0,499. Na cauda de 11–18/09, base de 59% de lavagem: fora das métricas principais.

15.4 Dados e rótulos

- **HI-Small é sintético.** O rótulo diz o que o simulador gerou como **lavagem**. Não é fraude em geral, não tem data de confirmação, e o fuso é presumido.
- **ACH concentra 87% da lavagem**, o que pode ser artefato do simulador. Wire e Reinvestment não têm nenhum caso.
- **Rede:** o rótulo é uma regra sobre a medição seguinte. O período da referência p95/p99 não está documentado.
- **Sem custos de erro** e sem capacidade de investigação fornecidos.

15.5 Reuso do teste

Confirmado. O período de teste foi consultado na avaliação de 26/10/2026, na comparação de 9 candidatos da auditoria e na reavaliação de 02/11/2026. O treino nunca leu rótulos do teste, e as escolhas foram feitas na validação. Mesmo assim:

- os números de teste **não são uma avaliação inédita**;
- diferenças pequenas (0,750 × 0,752; 0,461 × 0,464) não são melhoria comprovada;
- XGBoost na lavagem teve AP de teste 0,509 contra 0,461 da RF, na comparação da auditoria, mas é **candidato**: a AP de validação variou de 0,27 a 0,55 entre tentativas. Na rede, empate (IC de 95% da diferença entre −0,0030 e +0,0057);

- antes de trocar modelo: congelar pela validação e medir uma vez em período novo.

Os dias 03/09 e 10/09 usados nas demonstrações deste manual não ajustaram nada.

15.6 Desempenho computacional

Qualidade preditiva e desempenho são coisas diferentes. **Medido em 06/11/2026** com `scripts/benchmark_eventos.py`, em execução isolada: Windows 11, 20 CPUs lógicas, Python 3.14.0, servidor local, registro durável com fsync ligado. Relatório completo: `docs/ml/BENCHMARK_EVENTOS.md`. Valem para esta máquina e execução; há variação grande entre execuções (o custo por minuto foi de 15,4 ms em 03/11 e 7,8 ms agora, sem mudança nesse caminho).

Medida	p50 / p99 ou valor	Inclui
Gravar 1 evento com fsync	0,27 / 0,48 ms	Só o registro
Aceitação HTTP de 1 medição	27 / 34 ms	Pedido local, validação, fsync, resposta
HTTP até a previsão gravada, 1 medição	46 / 69 ms	+ fila, modelo, CSV. **Sem** atualização visual do navegador, que consulta a cada 2 s
Processamento interno, 1 medição	34 / 49 ms	Sem HTTP
Modelo isolado, 1 medição	19 / 26 ms	Só `predict_proba`
Vazão em lote do trabalhador (rede)	10.199 eventos/s	Em processo, sem HTTP, sem fsync por evento. **Não é capacidade da API**. Latência nessa vazão: p99 de 1,4 s
Atributos + score de um minuto fechado	7,8 / 13 ms	**Sem** a espera para fechar, HTTP e persistência
Custo amortizado por transação	0,06 / 0,07 ms	Minuto ÷ transações do minuto
Replay financeiro pelo serviço	11.204 transações/s	Registro, fila, modelo, CSV
Espera pelo fechamento do minuto	Da ordem de 1 min em eventos novos	Política, não custo
Recalcular 1 transação pelo caminho em lote	5,4 a 5,6 s	Reindexa 5 milhões de linhas
Recuperação só pelo registro	46.105 eventos em 2,3 s	Rede, sem instantâneo
RAM do estado com 4,87 milhões de transações	285 MB	Processo novo, depois de restaurar
Instantâneo em disco	166 MB depois da carga; 242 MB no fim do dia	Arquivo; não é RAM

Medições históricas, de antes do registro durável (03/11/2026): 15,6 mil eventos/s no trabalhador; 32 ms em baixa carga. Não valem mais para esta versão. A capacidade HTTP sob carga não foi medida.

15.7 Limitações principais

Tema	Limitação	Consequência
Dados	Lavagem aprendida e medida só em dados sintéticos	Desempenho em dados reais é desconhecido
Integração	Sem vínculo entre transações e rede	Nenhuma pontuação usa rede
Cobertura	Positivos sem padrão: recall de 0,02	O recall global superestima esquemas desconhecidos
Histórico	Sem passado, os alertas caem muito	Primeiras 72 h de uma análise são pouco confiáveis
Avaliação	Teste reutilizado	Números não são inéditos

Tema	Limitação	Consequência
Grafos	Interface estática; defeitos A1 a A7	Use a CLI e leia a seção 8.7
Operação	Um trabalhador, estado em memória, sem autenticação	Só `127.0.0.1`; não é sistema de produção
Fonte de dados	Sem conexão real	Demonstração local
Minuto financeiro	Não reabre	Transação atrasada não é pontuada
Armazenamento	A interface não apaga análises; cada uma guarda uma cópia da entrada	Disco cresce até limpeza manual
Lote × incremental	Corrigido em 09/11/2026: o lote agora soma por conta e coincide com o incremental	O modelo atual foi treinado com o lote antigo; com o corrigido, nenhum alerta muda no teste do HI-Small

15.8 Próximos passos de maior valor

Obter dados com vínculo verificável e rótulos com data; reservar período novo para confirmação; corrigir A1 a A7; decidir sobre `rede_v2`, que depende da referência p95/p99; revisar os limites dos motivos. Os dados externos necessários estão em `docs/ml/EVENTOS.md`, seção 9.

16 Referência técnica e reprodução

16.1 Instalação

```
python -m venv .venv
```

Ative o ambiente (`.venv\Scripts\Activate.ps1` no Windows; `source .venv/bin/activate` no Linux/macOS). Depois:

```
python -m pip install -r requirements.txt -r requirements-ml.txt
```

O treino documentado usou Python 3.14.0, numpy 2.5.4, pandas 3.1.0 e scikit-learn 1.9.1. O artefato do modelo não vem no repositório: gere-o com `treinar`, com os dados em `ml_config.local.toml` (copie de `ml_config.exemplo.toml`).

16.2 Comandos

Comando	O que faz
`python src/sentinel_ai.py`	Servidor e interface em `http://127.0.0.1:5000/`
`python src/main.py --input dados/exemplo_transacoes.csv --scc --centralidade`	Grafos
`python src/main.py --input arquivo.csv --export-json --output nome`	Grafos, com JSON
`python -m src.ml.cli auditar --fonte todas`	Audita os dados
`python -m src.ml.cli treinar --tarefa todas`	**Treina** e salva o artefato
`python -m src.ml.cli avaliar --tarefa todas`	Avalia no teste (já reutilizado)
`python -m src.ml.cli prever --tarefa estado_rede --entrada a.csv --saida s.csv`	Inferência de rede, sem sessão
`python -m src.ml.cli prever --tarefa lavagem --entrada a.csv --historico h.zip --saida s.csv`	Inferência de lavagem, em lote, sem sessão
`python -m src.ml.cli tarefas`	Cabeças e pendências da fusão
`python docs/exemplos/gerar_exemplos_inventados.py`	Refaz os arquivos do tutorial
`python scripts/produtor_eventos_exemplo.py --sessao <id> --tipo rede --limite 500`	Produtor; o id aparece na área Eventos
`python scripts/benchmark_eventos.py`	Benchmark, com o servidor parado
`python docs/gerar_pdf_como_funciona.py`	Gera este PDF (`pip install markdown pymupdf`)
`python -m pytest testes`	Testes

16.3 Fluxos para reproduzir

Analisar um dataset: seção 4.

Queda e recuperação pela API:

1. Em `#ml/eventos`, use **Iniciar processamento** e **Gravar estado agora**.
2. Envie eventos com o cabeçalho `X-NodeWatch-Sessao` (a tela mostra o id).

3. Mate o processo do servidor à força e inicie-o de novo.
4. Veja **Recuperação pendente** e use **Recuperar e iniciar**.
5. Reenvie os mesmos eventos: voltam em `ja_aceitos`.

Replay: em `#ml/eventos`, use Iniciar replay (exige `python -m src.ml.cli exemplos`). **Laboratório:** Executar laboratório de simulação.

Rotas da API: `docs/ml/EVENTOS.md`, seção 7, e `docs/ml/ANALISE_DATASETS.md`.

16.4 Arquivos

Arquivo	Responsabilidade
`src/sentinel_ai.py`	Servidor, página, chat
`src/api_ml.py`, `src/api_eventos.py`	Rotas de exploração; de sessão, eventos, análises e previsão
`src/main.py`, `src/grafo/graph.py`, `src/leitura/`	CLI, grafo, leitura e exportação de grafos
`src/algoritmos/`	Ciclos, SCC, centralidade, fan-out e fan-in
`src/ml/config.py`, `esquemas.py`, `ingestao.py`	Configuração, contratos, leitura
`src/ml/auditoria.py`, `experimentos.py`, `avaliacao.py`, `relatorio.py`	Auditoria, treino, métricas, relatório
`src/ml/preparacao.py`, `incremental.py`	Atributos em lote e por estado
`src/ml/modelos.py`, `previsao.py`	Modelos, cabeças, inferência
`src/ml/analises.py`, `sessoes.py`	Datasets novos; sessões
`src/ml/eventos.py`, `registro_eventos.py`, `servico_eventos.py`, `replay.py`	Contrato, registro, serviço, replay
`src/ml/integracao.py`, `simulacao.py`	Junção com a rede; laboratório
`src/ml/exploracao.py`	Leitura de previsões, filtros, exportação
`interface/index.html`	Toda a interface
`scripts/`	Produtor, benchmarks, conversor do IBM AML
`docs/ml/`	Relatório, dicionário, contratos, eventos, datasets, benchmark, revisão, evidências
`artefatos_ml/`	Gerado; ignorado pelo git

16.5 Verificações deste manual

Executadas em 06/11/2026:

Verificação	Resultado
`python -m pytest testes`	193 aprovados, 0 falhas
CLI de grafos com o exemplo	Saída da seção 6.5
`src.ml.cli tarefas`; `prever` de rede	Funcionaram
Tutorial e exemplos mínimos, com o modelo real	Saídas das seções 4, 7 e 12
Interface em Chrome headless, com arquivos fora dos exemplos	`docs/ml/evidencias/demo_*.txt`
Benchmark isolado	`docs/ml/BENCHMARK_EVENTOS.md`
Números da seção 15 contra `docs/ml/resultados/*.json`	Conferidos por script

Não confirmado: Sentinel AI com chave real; queda de energia ou do sistema operacional; aba oculta em outros navegadores; carga HTTP concorrente; o chat em relação aos dados atuais do painel; treino completo (não foi refeito).

Revisão completa de falhas: `docs/ml/REVISAO_CONFIABILIDADE_EVENTOS.md`.

17 Glossário

Termo	Significado
ACH	*Automated Clearing House*: transferência eletrônica em lote.
Alerta	Score acima do limiar. Pedido de atenção, não conclusão.
AML	*Anti-Money Laundering*: prevenção à lavagem de dinheiro.
AP	*Average Precision*: qualidade da ordenação de uma classe rara.
Artefato	Arquivo com o modelo treinado.
Atributo	Número de entrada do modelo, também chamado *feature*.
Baseline	Resposta simples usada como régua mínima.
Cabeça	Parte do `ModeloUnificado` responsável por uma tarefa.
Checkpoint	Progresso gravado de uma análise, de onde ela pode continuar.
Conflito	Mesma identidade com conteúdo diferente.
Deriva	Dados novos com distribuição diferente da do treino.
DFS	*Depth-First Search*: busca em profundidade.
Fan-out / fan-in	Conta que envia para, ou recebe de, muitas contas em pouco tempo.
fsync	Pedido ao sistema operacional para gravar de fato no disco.
Inferência	Aplicar o modelo a dados novos, sem alterá-lo.
Instantâneo	Cópia do estado do serviço; ponto de recuperação.
Jitter	Variação do atraso entre pacotes.
Lavagem de dinheiro	Dar aparência legal a dinheiro de origem ilícita.
Limiar	Score a partir do qual há alerta.
LLM	*Large Language Model*: modelo de linguagem; só no Sentinel AI.
Multigrafo direcionado	Grafo com setas, que admite várias entre o mesmo par.
Persistência	Baseline que repete o estado atual.
Point-in-time	Cálculo que só usa o que já tinha acontecido.
Ponto seguro	Onde o trabalho pode parar sem deixar nada incoerente.
Projeção	Arquivo que pode ser refeito a partir de outra fonte.
PSI	*Population Stability Index*: medida de deriva.
Registro durável (WAL)	Arquivo em que o evento é gravado antes de ser aplicado.
Replay	Reenvio de um arquivo existente como eventos.
Rótulo	Resposta certa conhecida de um exemplo.
RTT	*Round-Trip Time*: tempo de ida e volta de um pacote.
SCC	*Strongly Connected Component*: grupo em que todos alcançam todos.
Score	Nota do modelo. Não é probabilidade de fraude.
Sentinela	Valor especial (−1) que significa "não medido".
Sessão	Autorização temporária de uma aba para processar.
Sintético	Gerado por simulador, não vindo de operações reais.
Supervisionado	Aprendizado com exemplos de resposta conhecida.

Termo	Significado
Vazamento	Uso de informação indisponível na hora da previsão.

18 Referências

- ALTMAN, E. et al. Realistic Synthetic Financial Transactions for Anti-Money Laundering Models. NeurIPS 36, 2023. arXiv:2306.16424.
- BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. *KDD*, p. 785–794, 2016.
- CORMEN, T. H. et al. *Introduction to Algorithms*. 3. ed. MIT Press, 2009. Cap. 22.
- FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001.
- HARRIS, C. R. et al. Array programming with NumPy. *Nature*, v. 585, p. 357–362, 2020.
- KE, G. et al. LightGBM. NeurIPS 30, 2017.
- LOPEZ-ROJAS, E. A.; ELMIR, A.; AXELSSON, S. PaySim. *EMSS*, 2016.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *JMLR*, v. 12, p. 2825–2830, 2011.
- SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot. *PLoS ONE*, v. 10, n. 3, 2015.
- SHARIR, M. A strong-connectivity algorithm and its applications in data flow analysis. *Computers & Mathematics with Applications*, v. 7, n. 1, p. 67–72, 1981.